

analysis

Concepción Paz*, Adrián Cabarcos, Miguel Concheiro, Marcos Conde-Fontenla

Cintecx, Universidade de Vigo, 36310 Vigo, España

*対応する著者。電子メールアドレス: cpaz@uvigo.gal

Abstract

沸騰現象の正確な監視と予測は、信頼できる操作にとって重要です。熱システムの危機的条件に近い。この点で、この研究は応用に焦点を当てています。沸騰を識別するための画像分類のための畳み込みニューラルネットワーク (CNN) アルゴリズム体制。具体的には、ディープラーニングモデルのトレーニングに使用される画像はベースで取得されました。ジュール効果加熱を伴うフローボーリングの実験セットアップ。4つの異なるCNNアーキテクチャ。さまざまな動作条件下で沸騰現象を分類するために採用され、カバー。単相流、核形成沸騰、および批判的な熱流束状態。この研究では、作業液と加熱に応じて画像を分類する際のモデルの堅牢性。プレート (テキストチャなしおよびマイクロテキストチャ)。各CNNのパフォーマンスは、使用して評価されました。精度、リコール、およびFスコアメトリック、および以前に報告された方法論と比較。ダウンサンプリング、主成分分析、およびサポートベクターマシンを含む。調査結果は、沸騰体制を正確に分類する際のCNNアルゴリズムの有効性を強調しています。画像から、以前の方法論を上回る。特に、InceptionNetはf-を達成しました。プレートタイプ分類のスコアは約98%です。Alexnetは両方に最高のパフォーマンスを示しました。Fスコアが95%を超える沸騰レジームと流体タイプの分類。対照的に、前の方法論は、これらの分類で最大Fスコアを約88%に達成しました。

キーワード: フロー沸騰、畳み込みニューラルネットワーク、CHF、ディープラーニング、コンピュータ Vision.

Nomenclature

α, β	学習率と減衰係数
C	ペナルティ期間コスト関数
\mathcal{C}	勢いマッピング関数
\mathcal{L}	スラック変数
m	重量係数のベクトル 壁の温度

$\phi(x)$

ξ

w

T_{wall}

Acronyms

CHF	臨界熱流束 畳み込みニューラル
CNN	ネットワーク 深い学習 ベクタ
DL	マシンをサポートします
SVM	核沸騰の開始
ONB	

31 1. Introduction

32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62
63 64 65 66 67 68 69 70 さらに、高速カメラの使用に基づく非侵入研究も 71
自然対流、プールの沸騰、移行の間の有意差を検出できる 72
沸騰、フィルム沸騰体制[20]。沸騰した画像は、かなりの注目を集めています 73
実験セットアップを通じてキャプチャされたフレームは、バブルに関する詳細で貴重な洞察を提供します 74
レシメンに関連し、費用対効果の高い携帯方法であるダイナミクス。 75
Al-Hindawiらによる最近の研究。[21]は、検出の根本的な重要性を強調しています 76
CHFとイメージによる開発に貢献する主要なメカニズムを理解する 77
分析。それにもかかわらず、そのようなデータの利用はしばしば欠点を伴い、主にに関連付けられています
78 時間のかかるプロセス。この意味で、ディープラーニングの最近の進歩(DL)が役立つ場合があります 79
沸騰アプリケーションでの画像処理と自動データ抽出。たとえば、ホボルド 80 Da Silva
[20]は、93%以上の精度を達成する機械学習方法論を提案しました 81
主成分分析(PCA)を適用することにより、プールの沸騰体制を特定する 82
次元の削減に続いて、サポートベクトルを含む監視された学習アルゴリズムが続きます
83 マシン(SVM)およびニューラルネットワーク。同様のアプローチが後に熱流束に採用されました 84
核沸騰フレームの定量化[22]。ただし、これらの前のことに注意する必要があります

別のメモで、Ponter and Haigh [17]による先駆的な研究が音響の使用を調査しました
泡からの排出は、沸騰の存在に伴うことを示唆しています
音。沸騰曲線に沿って観察されるこれらの沸騰音の変化は注意することができ、
したがって、音響排出は、沸騰体制分類の目的で利用できます。最近、Sinha et
al. [18]この方法を採用して、音響信号を使用してCHFのin-situ検出を実施しました。
沸騰危機中にフィードバック制御を提供しました。彼らのアプローチには、の分析が含まれていました
さまざまな沸騰段階での可聴音の周波数スペクトルとピークのシフトの検出
CHFでの頻度。ただし、実際の産業環境では、
ターゲットの音響信号を高レベルと区別するための音響分析の重要な課題
バックグラウンドノイズ[19]。

85 研究では、機械学習をその後に適用するための次元削減アプローチを適用しました。 86
 一方、近年、畳み込みニューラルネットワーク (CNNs) が DL のタイプとして浮上しています 87
 画像処理と認識タスク用に特別に設計されたアルゴリズム。それらと比較して 88
 機械学習モデル、CNN は自動的に学習できるため、より少ない処理が必要です 89
 生の入力画像からの特徴表現 [23]。実際、最近の研究が実証されています 90
 熱流束の予測やローカルバブルの追跡などのタスクに対する CNNs の有望な適用 91
 バブル生成、合体、衝突、マージ、破裂イベントを含む行動 [24]、 92
 [25]。さらに、CNN は凝縮流を区別するのに効果的であることが証明されています 93
 水平円形のチューブにおけるメタンとテトラフルオロメタンのパターン画像、達成 94
 90% を超える精度 [26]。 95 96 97 98 99 100 101 102 103 104 105 106 107 108

109

110 ディープラーニングアルゴリズムのトレーニングとテストに使用されるデータは、
 111 図 1.a. に示す実験セットアップ。このセットアップは、以前の研究で広く説明されています [7]、[30]、
 112 [31] は、2 つの主要な部分で構成されています。図の青い破線で概説されている研究セクション
 113 1.a. およびメイン変数の調整と測定を促進する補足サブシステム
 114 バルク温度、圧力、体積流量など。具体的には、調査セクション この作業で採用されているのは、10
 115 x 25 x 320 mm の長方形のチャネルで構成されています
 116 調整可能な傾斜。さらに、この特定の研究では、この壁の熱流束が生成されました 電力源を使用した 1
 117 mm の薄いステンレス鋼プレートのジュール加熱。もっと
 118 この加熱方法の詳細な検査は、参照 [32] で見つけることができますが、
 119 この特定の流れの沸騰セットアップに関連する不確実性については、参照 [7] で説明しています。

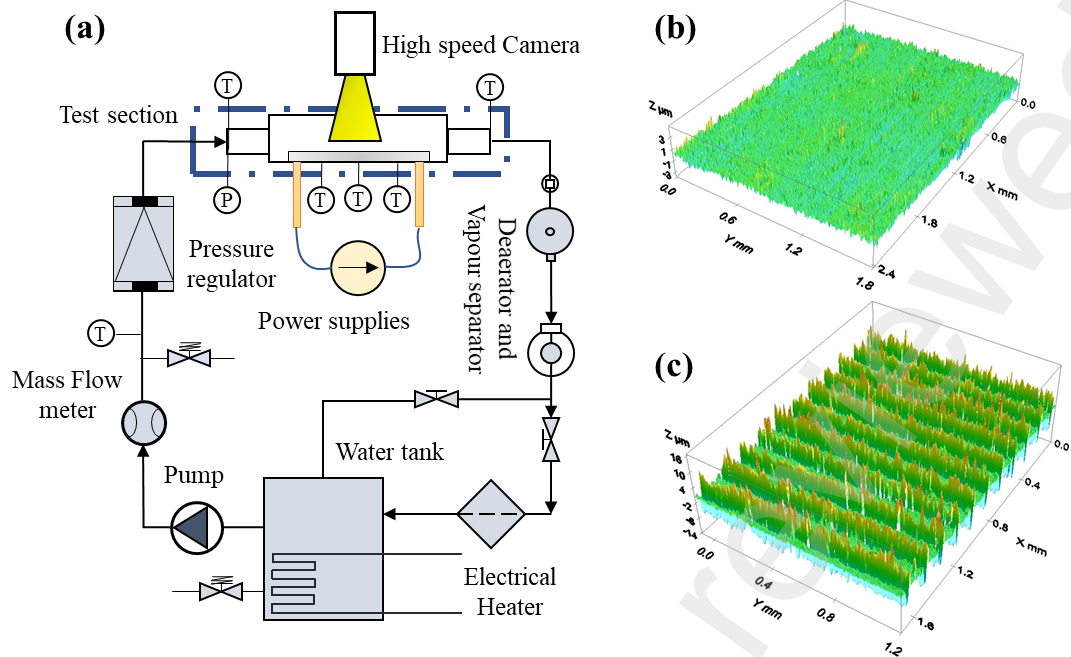


図1. (a) 流量の沸騰実験セットアップの概略図。 (b) テクスチャされていないプロファイル surface. (c) Profile of a transversal direction micro-textured surface.

to = 314 および = 406 一方、2番目のタイプにはaが組み込まれています
このマイクロテクスチャされた表面のうち、rough = 1.68 および =
2.8に等しい粗さパラメーターを生成します 1
。また、このプレートタイプグループ内で、両方のマイクロテクスチャが

YB : KYW (Ytterbiumを使用して準備された、参照プレートのマイクロテクステッド表面変更 520
nmの波長のレーザー源。具体的には、このプロセスには、 2.1×10^{12}
w/cm²の放射照度が適用されました。図1.Cは測定を示しています

longitudinal and transverse directions were considered for this work.

実験方法については、特定の動作条件が定義されると、この手順は、以前の研究で詳述されているア
プローチに従いました[7]。具体的には、テストが実施されました 入口速度 (0.2 ~ 0.8
m/s) の変動、入口温度 (20 ~ 95 °C)、圧力 (130 ~ 220
kPa)、およびチャネルの傾斜 (0°、180°、225°、および270°)。3つの異なる作業液
使用されました：蒸留水、50%エチレングリコール (例えば) -
水の混合物、およびフルオロエーテル。両方
これらの実験では、参照プレートとマイクロテクスチャの加熱プレートも考慮されました。

手順では、加熱板に適用される電力を徐々に増やすことが含まれます 0.5 Aの増分で電流を調整 0.1
mW/cm² ことの間隔。核沸騰の開始前にキャプチャされたフレームはあった
「非ボイル」に分類され、核沸騰領域のONBの後に「沸騰」として分類され、
撮影した画像の最後の記録は、その特定のテストの重要な熱流束が達成された場合、
「Pre-Chf.」その結果、3800の画像を含むデータベースがトレーニングに使用されました
ディープラーニングモデル。さらに、この特定の画像から取得した画像の実例コレクション
これらの各グループに分類されたフロー沸騰セットアップは、付録Aにあります。

3. Deep learning models

セクション2で概説されている実験的セットアップと方法論からの描画、のデータベース 沸騰曲線に沿ってさまざまな点でキャプチャされた画像が得られました。このデータセットには含まれます3つの異なる流体と2種類のプレートで実施された観測(テキストチャ化されていないおよび微小 テクスチャー)。このデータセット、ディープラーニングアルゴリズム、特にCNNモデルを利用することができ、画像内のパターンを自律的に識別し、トレーニングに基づいて新しいフレームを分類します。具体的には、この研究では、4つの異なるものを考慮した比較分析を提示します。アーキテクチャ (ResNet、InceptionNet、AlexNet、および参照として使用される基本的なCNNアーキテクチャ)、以下に説明します。

3.1. Overview of CNN architectures

畳み込みニューラルネットワークは、空間を実施するフィードフォワードネットワークとして分類されます。既存のデータのマッピング[33]。このプロセスはデータを新しい空間に変換し、関連する機能の識別。さらに、CNNモデルは3つのプライマリで構成されています。層の種類：畳み込み層、プーリング層、および完全に接続された層。これらのそれぞれレイヤーは、[34]、[35]の以下で簡単に概説します。

畳み込み層。このレイヤーは、関連する画像特性を抽出することを可能にします。畳み込みフィルターを使用します。このプロセス中、入力画像は畳み込みを受けます。nフィルターを使用して、N機能マップになり、それぞれがユニークな機能を強調します。畳み込み操作には、入力画像全体で水平および垂直にフィルターをスライドさせることが含まれます。その後、結果のマップに非線形活性化関数が適用され、最終出力機能マップ。

プーリングレイヤー。これらのレイヤー内では、畳み込み層から抽出された必須の特徴は保存され、ダウンサンプリングにより、機能マップの空間解像度が削減されます。これプロセスにより、CNNsは多数の入力マトリックスを効果的に処理できるようにします。画像などの要素。通常、2つの主要なプーリング層が採用されています：最大プーリングと平均プーリング。maxプーリングは、の各パッチ内の最大値を選択します。機能マップは、平均プーリングが各パッチ内の平均値を計算します[34]。

完全に接続されたレイヤー。このレイヤーは、従来の完全に接続されたものと同様に機能します。従来の機械学習モデルのネットワーク。から生成された出力を受信します。CNNの初期層。畳み込みおよびプーリング操作が繰り返して適用されます。これに続いて、出力は完全に接続されたレイヤーに送信されます。出力は、重みベクトルと入力の間でドット積を計算することにより決定されます。ベクター。

これらの以前のレイヤーの適切な組み合わせに基づいて、多数のアーキテクチャが時間の経過とともに提案[36]。この作業で検討されている各アーキテクチャの説明は以下に提供されています。

基本的なCNN。この用語は、画像の最も基本的なCNNアーキテクチャの1つを指します。で示されているように、2つの畳み込み層とプーリング層のみを含む処理[37]、[38]。図2。このネットワークは、より多くのパフォーマンスを比較するための参照モデルとして機能します。高度なモデル(具体的にはAlexNet、ResNet、およびInceptionNetも以下で説明します)。この特定の研究では、図2の各レイヤーの技術的な詳細を詳細に示します。付録Bでは

AlexNet。このアーキテクチャは、5つの畳み込み層と3つの完全に接続されているもので構成されています。図2に示すように、レイヤー。特に、それは先駆的な深い畳み込みの1つでした。従来のシグモイド活性化関数を置き換えるニューラルネットワーク。整流された線形ユニットを備えた畳み込み層は、と比較してパフォーマンスが向上します。以前のネットワーク。さらに、最後の最大プーリング層の後、出力は

ベクトル、次に最初の完全に接続された層[36]に転送されます。元のアーキテクチャでは、最終的に完全に接続されたレイヤーは、1000個のニューロンで構成され、クラスの数に合わせます。ネットワークが最初にトレーニングされたデータセットで、ただし、この特定の作業では、最終接続の数は、調査のクラスの数に基づいて調整されました。詳細図2に描かれている各レイヤーを付録Bに示します。

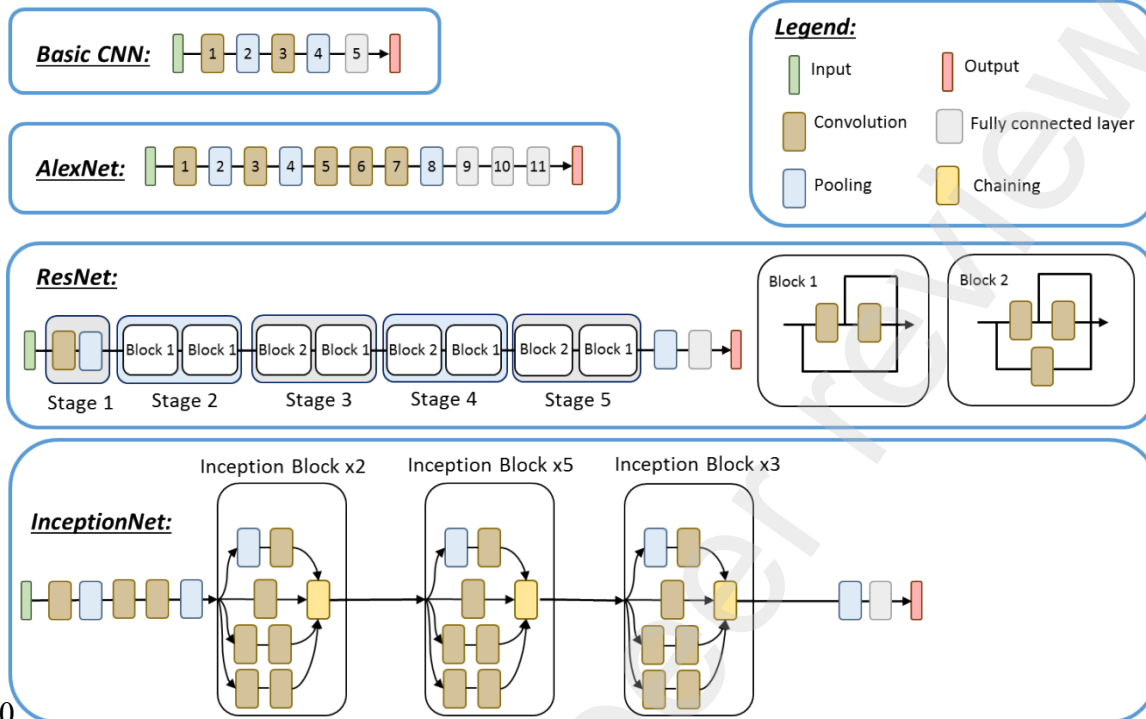


図2。この研究で考慮されたCNNアーキテクチャに関する概略[35 – 37]、[40]、[41]

残留ネットワーク（ResNet）。このアーキテクチャは、ネットワークの効率を高めることを目指しています。アイデンティティ接続とも呼ばれるショートカット接続を導入することによるトレーニング[39]。これら接続により、情報が1つ以上のレイヤーをスキップできるようにします。これにより、問題の克服に役立ちます。深いネットワークでよく見られる消失グラデーションの。以前からのアクティベーションを使用することにより、これらのショートカットは学習を加速し、パフォーマンスの劣化を防ぎます。テクニカル図2に示す各段階の詳細は、付録Bにあります。

- InceptionNet。図2にわかるように、このアーキテクチャはその利用に際立っています。多様なフィルターサイズを備えた複数の平行畳み込み層により、ネットワークがキャプチャできるようになります。さまざまなスケールと解像度にわたって同時に機能します。CNNとは対照的に、通常、レイヤーごとに単一のフィルターサイズを使用するAlexNetのようなアーキテクチャ、インセプションはさまざまなサイズのフィルターの組み合わせを同時に使用します。これはによって達成されます。プーリング操作とともに、 1×1 、 3×3 、および 5×5 の畳み込みを同時に適用する[36]。その後、これらの操作から生成された出力は連結され、合格されます。次のレイヤーに。図2に示すインセプションブロックのより深い概要では、参照[40]で見つかりました。

3.2. Implementation and performance assessment

セクション3.1で詳述されているアーキテクチャは、Matlab 2023およびDeepを使用し訓練されました。学習ツールボックス。特に、各アーキテクチャの前処理ステップとして、画像は表1に描かれている考慮事項に従って、再スケーリングおよび変換されました。

表1. 選択したアルゴリズムに従って入力画像に必要な前処理

Algorithm	Pre-processing
AlexNet	227 x 227ピクセルにサイズ変更された入力画像。RGBスケール
ResNet	224 x 224ピクセルにサイズ変更された入力画像。RGBスケール
InceptionNet	224 x 224ピクセルにサイズ変更された入力画像。RGBスケールの3チャンネル
CNN reference	Input images resized to 180 x 448 pixels. Single-channel images in grey scale

222

223

224

225

226

227

228

229

230

231

232

233

234

さらに、单相流を表す画像の特定の場合（つまり、撮影したフレーム
ONB以下の熱流束と壁温度の値の場合、したがって、沸騰が始まる前）、画像間の類似性によって引
き起こされるトレーニング中のバイアスを回避するために、ノイズがランダムに追加されました。
これらの例では、ガウスのぼかしと塩と耳のノイズがランダムに導入されました
画像[36]。その後、データセットは2つの部分に分割されました：トレーニングの80%と20% テスト
[42]、[43]。この頻繁なパーティション化により、モデルが多様でトレーニングされることが保証さ
れました。また、目に見えない情報でのパフォーマンスの評価を可能にしながら、画像のセット。さら
に、これらのモデルのトレーニングには、適切なオブティマイザーの選択が含まれます。これは重要で
す。ニューラルネットワークのトレーニングにおけるコンポーネント。オブティマイザーは、モデルの
重みと方法を決定します
トレーニング中にパラメーターが更新され、損失を減らしながら精度を向上させます。具体的には、
この作業では、運動量（SGDM）オブティマイザーを伴う確率勾配降下が考慮されました。その
更新ルールは、式に従って数学的に表現されます。1 [44]。

ここで、 τ は反復時の勢いを表します。特定のコスト関数のレートの変更を示します
weight重量に関して[45]。さらに、この研究では、3つのメトリックを使用して評価しました

235

236

237

238

239

240

241

242

243

244

245

246

247

248

249

250

251

252

253

254

モデルのパフォーマンスを比較します：精度、リコール、およびFスコア。精度はの比率を測定します
総予測される正のインスタンスに対して正しく予測された正のインスタンスが正しく予測され、その方
法を示します
正確には、正の予測は全体的な正確性を反映しています[46]。リコールは画分を定量化します
モデルが正常に肯定的であると正常に識別する実際の肯定的なケースの。ただし、精度はできません。不
均衡なデータセットで誤解を招くように、支配的なクラスは無視しながら精度を膨らませることができ
るのでマイノリティクラス。Recallは正のインスタンスのみに焦点を当て、誤検知を見落とす可能性が
あります。
Fスコアは、精度とリコールを組み合わせ、バランスの取れた評価を提供します。計算します
正確さとリコールの高調波平均、偽陽性と偽陰性の両方を占める
[47]。リコールと精度のよつに、Fスコアが統一に近づくほどモデルが良くなります パフォーマンス。

さらに、これらのアルゴリズムでコミットされたエラーを適切に定量化するために、CNNアルゴリズム
HoboldとDa Silvaによって文献で報告されている以前の方法論とも比較されます
[20]。この方法論は、ブールの沸騰体制を識別するために以前の研究で適用されました
直接的な観測と間接的な観測の両方で、ここで取得したこのデータセットに直接適用されました セク
ション2で説明したフロー沸騰のセットアップから。具体的には、図3はこのアプローチを示していま
す。また、MATLAB 2023と統計および機械学習ツールボックスを使用して実装されました。

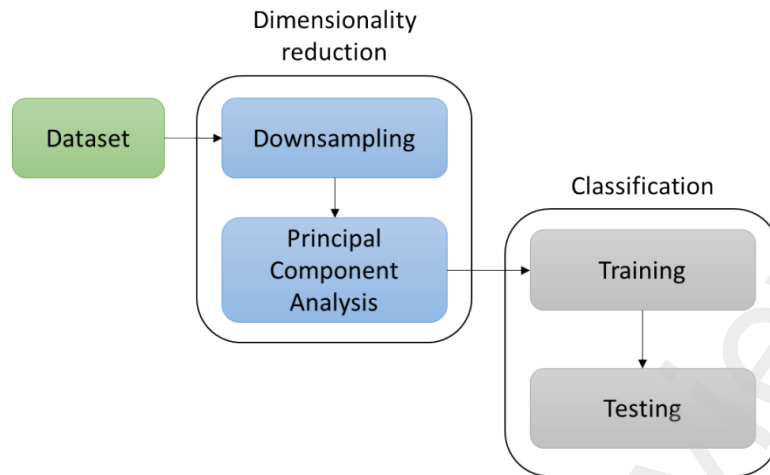


図3. プールの沸騰のためにHoboldとDa Silva [20]が提案した方法論のフローチャート
images classification by means of both direct and indirect observation.

Specifically, main stages of this approach are as follows:

次元削減。トレーニング前に画像の次元を減らすため機械学習モデル、Hobold、Da Silva [20]は、2段階のプロセスを提案しました。初め、ダウンサンプリングは、ダウンサンプリングを使用して、隣接するピクセルを地元で平均することによって実行されます。画像交差点分析に基づく5の因子。第二に、主成分分析はです。データセットをさらに簡素化するために適用されます。PCAは、保持中に変数の数を減らします。共分散マトリックスを取得することにより、ほとんどの変動性があり、そこから固有値と固有ベクトルは導出されます[48]。固有ベクトルは、最大変動の方向を示します（主成分）、および固有値はこの変動を定量化します。主成分その後、彼らが説明する分散によってランク付けされ、サブセットが選択され、還元データセットを形成します。これにより、元のデータの本質的な機能が保持され、最小限の分析が容易になります 情報の損失。

Classification. The dataset obtained from the dimensionality reduction stage can be used to train supervised learning algorithms. These groups of algorithms analyse input-output pairs from labelled training data to identify correlations between input and target variables, which can be continuous or categorical. In this study, a Support Vector Machine is employed, similar to the approach taken by Hobold and da Silva [20] in their research. They suggested that the similarity in classification scores across SVM and Neural Networks, both for direct and indirect observation, indicates the suitability of both types of algorithms for pool boiling regime classification. Specifically, SVM classifies both linear and nonlinear data by mapping the feature space to a higher-dimensional space through a nonlinear transformation [49]. The

このアルゴリズムは、ここで、

と

数学的に式2は、データを異なるクラスに分離する境界として機能します。最適なハイパープレーンを識別するこのプロセスには、コスト関数を最小限に抑えることも含まれます。

4. Results and discussion

このセクションでは、沸騰画像を分類するためのDLモデルの使用の比較を示します。HoboldとDalによって提案された次元削減方法との比較に加えてシルバ[20]。具体的には、セクション4.1では、アルゴリズムを使用して沸騰体系を分類します。セクション4.2は、プレートタイプの分類に焦点を当てています。セクション4.3では、流体タイプの分類について説明します(注: この特定のセクションでは、目に見える泡のない画像が分析から除外されています)。最後に、セクション4.4は、最高のパフォーマンスアルゴリズムの使用に関する4つの異なるケースについて報告しています。

4.1. Boiling regime classification

表2の結果は、それらに関する深い学習アルゴリズムの比較を示しています。沸騰体制分類におけるパフォーマンス。評価される指標には、精度、リコール、およびセクション3で説明されているように、「非ボイル」、「沸騰」、「沸騰」、「沸騰」、「沸騰」、「非ボイル」の3つのカテゴリのFスコア。表2。深い学習アルゴリズムと次元削減方法の比較

boiling regime classification.

Metric	Basic CNN		AlexNet		ResNet		InceptionNet		Dimensionality reduction method	
	Train (%)	Test (%)	Train (%)	Test (%)	Train (%)	Test (%)	Train (%)	Test (%)	Train (%)	Test (%)
Precision (Non-Boiling)	100	100	99.39	100	97.85	100	97.14	100	94.00	88.89
Precision (Boiling)	84.97	85.43	98.18	97.95	94.96	93.75	92.13	91.64	81.69	81.30
Precision (Pre-CHF)	89.26	90.25	100	99.28	97.05	98.33	91.75	90.09	88.67	88.12
Recall (Non-Boiling)	23.34	100	100	100	97.25	100	77.93	100	28.66	29.27
Recall (Boiling)	97.24	97.60	99.90	99.81	98.95	99.43	97.55	96.96	97.49	97.16
Recall (Pre-CHF)	81.22	78.92	93.45	92.61	82.88	79.19	82.62	81.25	61.74	59.73
F-score (Non-Boiling)	37.85	100	99.69	100	97.55	100	86.48	100	43.93	44.04
F-score (Boiling)	90.69	91.11	99.03	98.87	96.91	96.50	94.76	94.23	88.89	88.52
F-score (Pre-CHF)	85.05	84.21	96.61	95.83	89.41	87.73	86.94	85.44	72.80	71.20

精密指標に関しては、すべてのCNNモデルが両方で強いパフォーマンスを示しています。トレーニングとテストデータセット。たとえば、基本的なCNNはトレーニングで89.26%の精度を達成し、「Pre-CHF」インスタンスのテストでは90.25%であり、最小限の過剰適合を示しています。テスト中、alexnet、resnet、inceptionNet、および基本的なCNNはすべて、識別に100%の精度を達成しました。沸騰していないインスタンス。AlexnetとResnetは97.95%の高精度率を達成し、それぞれ「沸騰」カテゴリで93.75%、InceptionNetは密接に続いて91.64%。対照的に、基本的なCNNは、「沸騰」(85.43%)と「事前」の両方でより低い精度を示しました。chf (89.26%) カテゴリ。ここで、AlexnetとResnetが95%を超える値を達成しました。基本的なCNNと比較して優れたパフォーマンスを示しています。

リコールに関して、AlexNetはすべてのカテゴリ(92%以上)にわたって高いスコアを達成しました。最小値でより低いメトリックを達成したInceptionNetとResnetを上回る約80%。基本的なCNNは、特に「非沸騰」率を示しました。沸騰カテゴリ(30%未満)。精度とリコールのこの違いは、それを示唆しています。基本的なCNNは「非沸騰」(高精度)とラベル付けされたインスタンスを正確に識別しますが、おそらく保守的な予測のために、実際のインスタンス(低いリコール)を逃す可能性があります。

それに比べて、次元削減方法は、基本的なCNNですが、AlexNet、Resnet、InceptionNetなどの高度なCNNモデルに遅れをとったFスコアの条件。実際、この方法論は「非ボイル」で44.04%と71.20%を達成し、それぞれFスコアで「Pre-CHF」は、85%を超えるスコアよりも低かったです。

高度なCNN。また、HoboldとDaによって報告されたFスコア値が Silva [20] 彼らの研究では、特定のカテゴリに応じて、66%から95%の範囲でした。分類されています。これらの範囲で観察される矛盾は、異なるものの使用に起因する可能性があります。画像の種類（例：この研究では、その前の作業でのプールの沸騰に沸騰するフロー）とさまざまな実験条件。

全体として、これらの結果は、高度なCNNモデルが優れた能力を伴うことを示唆しています。沸騰を正確に分類する際の基本的なCNNと次元削減方法の両方。この特定のデータセット内のレジーム。特に、Alexnetは、で最高のFスコアを達成しました。テストデータセット（「Pre-CHF」クラスの95.8%など）は、これにおけるその有効性を強調しています。分類タスク。

4.2. Heating Plate-type classification

表3に、分類におけるこれらのアルゴリズムの結果の比較分析を示します。沸騰体制の分類でも観察されるいくつかの傾向を反映するプレートタイプ（セクション4.1）。この意味で、ResNetとInceptionNetは95%を超える精密レートを達成しました。沸騰体制の「非ボイル」や「沸騰」などのカテゴリ、これらのインスタンスを識別する正確さ。同様に、プレートタイプデータセットでは、これらのモデル「テキストチャされていない」および「マイクロテキストチャされた」カテゴリの両方で95%を超える精密レートを維持しました。正確な分類タスクにおける有効性を強調します。

表3. 深い学習アルゴリズムと次元削減方法の比較 regarding plate-type classification.

Metric	Basic CNN		AlexNet		ResNet		InceptionNet		Dimensionality reduction method	
	Train (%)	Test (%)	Train (%)	Test (%)	Train (%)	Test (%)	Train (%)	Test (%)	Train (%)	Test (%)
Precision (Non-Textured)	59.48	59.64	75.57	75.97	97.32	97.01	98.19	97.83	83.25	81.27
Precision (Micro-Textured)	100	100	100	100	95.44	93.68	97.58	98.52	86.40	81.76
Recall (Non-Textured)	100	100	100	100	96.87	95.58	98.53	99.01	92.19	89.34
Recall (Micro-Textured)	0.12	0.71	52.56	53.76	96.09	95.69	97.33	96.40	72.78	69.89
F-score (Non-Textured)	74.59	74.72	86.08	86.34	97.10	96.29	98.36	98.29	87.49	85.11
F-score (Micro-Textured)	0.25	1.428	68.90	69.93	95.76	94.68	97.58	97.45	79.01	75.36

ただし、沸騰体系とプレートとの間にリコールメトリックに顕著な違いがあります。タイプ分類。沸騰体制では、Alexnetはすべてのうち90%を超えるリコール率を達成しました。カテゴリ。ただし、プレートタイプのデータセットは、このメトリックに関してより多くの変動性を示しました。のためにたとえば、「マイクロテキストチャされた」カテゴリで、AlexNetはトレーニング中に52%のリコール率を達成しました。対照的に、ResNetとInceptionNetは優れたリコールを示しました。パフォーマンス、プレートタイプデータセットの両方のクラスの値が95%を超えるResNet、この特定のアプリケーションのAlexNetと比較して、より信頼性の高いモデルの選択を示します。さらに、リコールと精度の間の重大な格差に注意することも重要です。AlexNetで観察されたメトリック。たとえば、テスト中の「マイクロテキストチャされた」カテゴリでは、Alexnetは100%の精度を達成しましたが、わずか53.76%のリコールを達成しました。この矛盾は強調されています。精度とリコールメトリックのトレードオフ：高精度は、最小化する能力を反映しています。誤検知、低リコールは、肯定的なインスタンスを正しく識別する際の課題を示していますが、より多くの誤ったネガにつながります。

HoboldとDa Silva [20]によって提案された次元削減方法に関して、基本的なCNNと比較して、テキストチャされていない画像の改善された精度とリコールを実証しました、81.27%のテスト精度と89.34%のリコールを達成します。しかし、それは明らかにアウトパフォームされていました。ResNet (97.01%の精度、95.58%のリコール) およびInceptionNet (97.83%精度、99.01%

359 想起)。マイクロテクスチャされたデータの場合、次元削減方法は最も低い精度を示しました（81.7
360 6%）すべての方法の中で、基本的なCNNとAlexnetは100%の完全なスコアを達成しましたが、
361 ResNetとInceptionNetはそれぞれ93.68%と98.52%を達成しました。それにもかかわらず、
362 基本的なCNNと比較して、次元削減方法がより良いリコール（69.89%）を示しました（69.89%）1
363 0%より）。したがって、これらの結果は、HoboldとHoboldとSpodedによって報告された方法である
364 ことを示唆しています。Da Silva
365 [20]は、基本的なCNNよりも改善を実証し、有効性が低いことを示しました
すべてのメトリックのResNetやInceptionNetなどの高度なモデルと比較してください。

366 4.3. Fluid-type classification

367 存在に基づく流体型分類のためのアルゴリズムの適用に関して
368 画像の泡のうちに、表4は、精度、リコール、およびFスコアメトリック。
369

370 表4。ディープラーニングアルゴリズムと次元削減方法の比較
371 regarding fluid-type classification.

Metric	Basic CNN		AlexNet		ResNet		InceptionNet		次元削減方法 テスト電車 (%) (%)	
	Train (%)	Test (%)	Train (%)	Test (%)	Train (%)	Test (%)	Train (%)	Test (%)		
Precision (Water)	81.10	75.48	100	100	97.74	98.17	98.64	99.39	76.47	75.00
Precision (Hydrofluoroether)	60.93	100	96.96	100	98.99	100	96.83	100	77.95	80.99
Precision (EG-Water)	69.42	71.28	97.69	96.53	96.86	92.93	96.25	93.88	73.80	74.24
Recall (Water)	71.12	71.34	100	100	98.93	98.17	99.54	100	63.22	64.02
Recall (Hydrofluoroether)	51.07	100	99.61	100	99.57	100	95.32	100	83.04	77.34
Recall (EG-Water)	85.85	83.23	99.70	100	98.12	98.84	96.53	97.68	84.56	84.97
F-score (Water)	75.78	73.35	100	100	99.61	98.17	99.09	99.69	69.21	69.07
F-score (Hydrofluoroether)	55.56	100	98.26	100	97.32	100	96.07	100	82.00	77.65
F-score (EG-Water)	76.77	76.80	98.68	98.23	97.49	95.79	96.39	95.75	78.82	79.25

372 373
374 この意味で、AlexNetは、この特定のデータセットの最良のパフォーマンスの方法として見つかりました。
すべての流体タイプではほぼ完璧な精度、リコール、およびFスコアを達成し、その最低スコアで 375
EG-WATERのテストの精度は96.53%です。resNetは、特に、同等のパフォーマンスを発揮します
376 水とハイドロフルオロエーテル。ただし、Eg-waterの場合、そのパフォーマンスはわずかに低くなります
377 96.86%の精度と98.84%のテストのリコール。InceptionNetも高性能を示します。 378
379 特に水と加水分裂球のリコールとFスコアでは、マイナーも示しています
EG-水の精度の低下（93.88%）。 380 381 382 383 384 385 386 387 388 389 390 391 392

一方、基本的なCNNは、すべてのパフォーマンスメトリックが大幅に低いことを示しています
高度なモデルと比較した流体タイプ。その精度、リコール、および水のFスコア、
ハイドロフルオロエーテル、およびEG水は著しく低く、特にスコアがあるテストセットでは70~75%
の範囲をホバリングします。これは、基本的なCNNがもっと効果的ではないことを示しています
AlexNet、Resnet、InceptionNetなどの高度なアーキテクチャ。

同様に、次元削減方法は、AlexNetに比べてパフォーマンスが悪くなります。Resnet、およびInceptionNet。
基本的なCNNのパフォーマンスが向上したことを示していますが、特にハイドロフルオロエー
テルおよびエグウォーターのリコールとFスコアでは、比較的低い状態でまだ不足しています
スコア。たとえば、水は75%、ハイドロフルオロエーテルでは約77~79%の精度があります
テストの場合、CNNモデルのパフォーマンスを明らかに下回っています。さらに、それ
また、この特定のアプリケーションでは、次元削減のfスコアにも注意する必要があります
メソッドは、沸騰分類のためにHoboldとDa Silva [20]によって報告された範囲内にあります
目的（56%から97%の範囲）。

温度、

=

-

。円形マーカーは、記録ポイント

1876フレームにわたって平均された結果を示すラベルは、沸騰体制を分類するために使用されます

AlexNetネットワークへ。

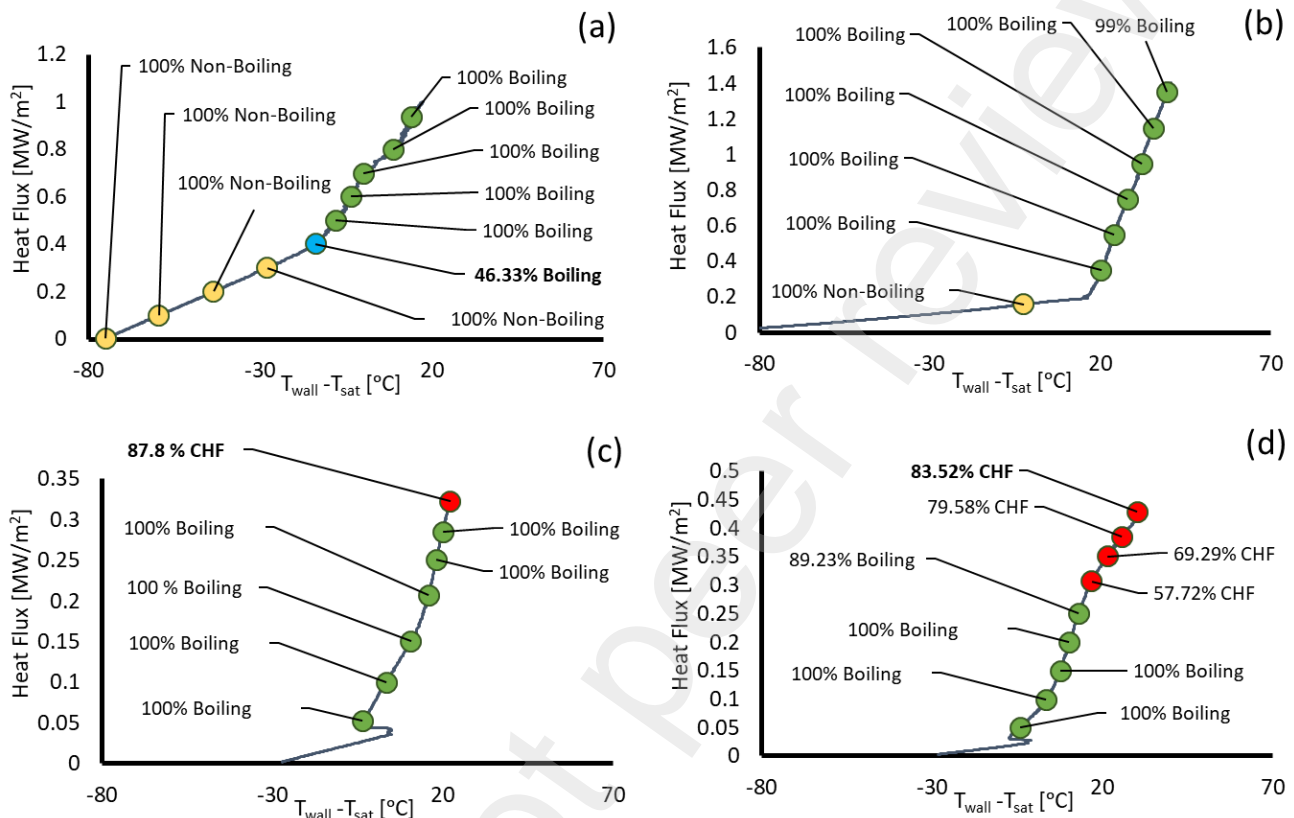


図4。沸騰曲線：(a) 入口温度が40 °Cの非テクスチャプレートの水、0.8 m/sの入口速度と1.75 barの圧力。(b) Eg-水、テクスチャ化されていないプレート、20 °C、0.2 m/s、1.75 bar。(c) インレット温度が40 °C、入口速度0.4のテクスチャ化されていないプレート上のハイドロフルオエーテル m/s、および1.3 barの圧力。(d) ヒドロフルオロエーテル、テクスチャードプレート、40 °C、0.2 m/s、1.3 bar。

これらすべての曲線で、初期直線は単相段階に対応します。の変化
勾配はONBをマークし、核沸騰領域の始まりを示します。図に示すように
4.a、この初期の単相ゾーンのポイントを表す黄色のマーカーは、正確に分類します
「非ボーリング」体制。次に、泡が形成され始めるONBにある青いマーカー、この時点でのフレーム
の46.33%が核沸騰、一貫性のあるものとして分類されていることを示しています
このフェーズの開始とともに、この点を超えて、残りのすべての画像は中に正しく分類されます
核沸騰領域（緑色のマーカー）。

図4.b：最初の黄色マーカーのEG-waterの場合にも同様の傾向が観察されます。
最初の直線では、単相領域と一致します。勾配が変化したら、示されます
沸騰する核形成への移行、その後のすべての記録ポイント（緑色のマーカー）は正確になります
この沸騰体制に分類されます。

図4.Cおよび4.Dに示すハイドロフルオロエーテルテストの場合、CHF条件は
到達すると、赤循環マーカーは、50%以上のフレームがあったビデオレコードを強調しています Pre-CHF
に分類されます。これらすべてのフレームは、核形成の開始後にPre-CHFとして分類されました
沸騰。具体的には、図4.Dは、Pre-CHFに分類された画像の割合が
赤循環マーカー内の熱流束が上昇すると増加します。最終的な録音ポイントで、約

421 フレームの85%はPre-CHFとして分類されており、潜在的に危険な状況を示しています
422 実験セットアップ。
423 最後に、液体とプレートの種類の分類に関して、図4.Dに示すケースは得られました
424 最低パフォーマンスメトリック。具体的には、核沸騰ゾーンのフレームの92.9%は
425 ヒドロフルオロエーテルとして正確に分類され、95.6%が関係すると正しく識別されました。テクスチャ
426 プレート。これらの結果は、トレーニングとテスト中に得られたメトリックと一致しています
427 セクション4.2および4.3へ。5。結論

428

429 430 431 432 433 434 いてフローの沸騰セットアップからキャプチャされた画像の分類に焦点を当て
435 436 437 438 439 440 状態（ボイルなし、核沸騰、またはPre-CHF状態）、プレートタイプ（テク
441 442 443 444 445 446 にはマイクロテクスチャ化）、および流体タイプ（たとえば、水、ハイドロフ
447 448 449 450 451 452 ）。
453 454 謝辞 455 456 457 ゴリズム（ResNet、AlexNet、およびInceptionNet）を基本と比較します。
458 付録a 459 460 461 さらに、これらの深い学習モデルはaと比較されます
と呼ばれる前述のアプローチ[20]
方法にはダウンサンプリングプロセスとマシンが続くことが含まれます
た学習段階。



沸騰状態に関して、AlexnetはF-で優れた性能を示しました。
スコアは95%を超え、ResNetとInceptionNetは同等の結果を示しました。3つすべて
アルゴリズムは、基本的なCNNと次元削減の両方を大幅に上回りました
50%未満のFスコアを達成した方法。

プレートタイプの分類では、InceptionNetとResNetがより良いパフォーマンスを示しました
Alexnetと比較して。次元削減方法は改善を示しましたが
基本的なCNNでは、ResNetやInceptionNetなどの高度なモデルよりも効果が低かった
すべてのメトリックにわたって。最後に、流体タイプの分類では、次元削減方法が再び AlexNet、Res
net、およびInceptionNetと比較してパフォーマンスが低い。たとえば、aを達成しました
水の75%、ハイドロフルオロエーテルおよびEG水の場合は約77~79%の精度
テスト中は、約90%を達成するCNNモデルよりも著しく低かった。

最後に、4つのユースケース（沸騰曲線）が分析され、
これらのケースのアルゴリズムは、テストとトレーニング中に取得されたメトリックに合わ
せて調整します。
これらの結果は、適切な分類アルゴリズムを選択することの重要性を強調しています。
アルゴリズムのパフォーマンスは、特定のタスクに基づいて大きく異なります。さらに、
Alexnet、Resnet、InceptionNetなど、他の科学ドメインで広く使用されているCNNモデル、
沸騰現象に関連する画像を効果的に分類する際にその価値を実証しました。



著者は、スペインの科学と革新のための金融省に感謝しています
PID2020-114742RB-I00プロジェクトをサポートします。オープンアクセス料金の資金：
Universidade de Vigo/Cisug。

このセクションには、この調査で使用されているデータセットの代表的な画像が含まれています。具体
的には、図A.1は、3つのフレームの例を示しています。
沸騰状態（非ボーリング、核沸騰、前CHF）。






図A. 1この研究で考慮された画像の例は、(a) ボイルなしとラベル付けされています。(b) 核形成 Boiling. (c) Pre-CHF state.

図A.2には、2つの異なる加熱プレートタイプの2つの画像が見つかります (テクスチャではありません or micro-textured).



図A. 2この研究で考慮された画像の例は、(a) 非テクスチャとラベル付けされています。(b) マイクロ - textured.

図A.3では、この作業で検討されている3つの流体に対応するバブル (例えば、水、Hydrofluoroether and Water) can be found.



図A. 3この研究で考慮された画像の例 (a) 水とラベル付けされた例。(b) Eg-water. (c) Hydrofluoroether.

Appendix B

表B. 1では、基本的なCNNを構成するプールおよび畳み込み操作が触発されました
by the sample structure found in references [37] and [38], can be found.

Table B. 1 Details of each layer composing the basic CNN used in this work.

Sequence of layers	Details
Convolution (1)	Kernel size = [3 * 3], Kernel number = [16], Stride = [1], ReLu
Pooling (2)	Pooling type = Max Pooling, Kernel size = [2 * 2], Stride = [2]
Convolution (3)	Kernel size = [3 * 3], Kernel number = [16], Stride = [1], ReLu
Pooling (4)	Pooling type = Max Pooling, Kernel size = [2 * 2], Stride = [2]
Fully Connected (5)	Softmax

表B. 2には、AlexNet構造[36]、[37]の各層のパラメーターが含まれています。

Table B. 2 AlexNet model.

Sequence of layers	Details
Convolution (1)	Kernel size = [11 * 11], Kernel number = [96], Stride = [4], ReLu
Pooling (2)	Pooling type = Max Pooling, Kernel size = [3 * 3]
Convolution (3)	Kernel size = [5 * 5], Kernel number = [256], Stride = [1], ReLu
Pooling (4)	Pooling type = Max Pooling, Kernel size = [3 * 3]
Convolution (5)	Kernel size = [3 * 3], Kernel number = [384], Stride = [1], ReLu
Convolution (6)	Kernel size = [3 * 3], Kernel number = [384], Stride = [1], ReLu
Convolution (7)	Kernel size = [3 * 3], Kernel number = [256], Stride = [1], ReLu
Pooling (8)	Pooling type = Max Pooling, Kernel size = [3 * 3]
Fully Connected (9)	4096 neurons
Fully Connected (10)	4096 neurons
Fully Connected (11)	Softmax

表B. 3は、ResNet構造の各段階のパラメーターを示しています[41]、[45]。

Table B. 3 ResNet model.

ResNet Stages	Details
畳み込みステージ1	(Kernel size = [7 * 7], Kernel number = [64]) + Max Pooling [3 * 3]
畳み込みステージ2	Kernel size = [3 * 3], Kernel number = [64]
畳み込みステージ3	Kernel size = [3 * 3], Kernel number = [128]
畳み込みステージ4	Kernel size = [3 * 3], Kernel number = [256]
畳み込みステージ5	Kernel size = [3 * 3], Kernel number = [512]
Pooling	Pooling type = Average Pooling, Kernel size = [7 * 7]
Final stage	Softmax

References

- [1] M. Jamialahmadi, C. Branch, and H. Müller-Steinhagen, "Augmentation of Nucleate Boiling by Additives," in *Transport Phenomena in Heat and Mass Transfer*, J. A. REIZES, Ed. Amsterdam: Elsevier, 1992, pp. 539–549. Doi: 10.1016/B978-0-444-89851-7.50052-2.
- [2] Z. Cao, Z. Wu, M. Faghri, and B. Sundén, "Coating engineering for boiling heat transfer toward immersion cooling," in *Advances in Heat Transfer*, vol. 53, J. P. Abraham, J. M. Gorman, and W. Minkowycz, Eds. Elsevier, 2021, pp. 97–158. Doi: 10.1016/bs.aiht.2021.06.002.
- [3] Y. Soffer, Y. Aharon, and G. Ziskind, "Experimental investigation on incipient boiling in narrow closed gaps with water," *International Journal of Thermal Sciences*, vol. 191, p. 108333, 2023. Doi: 10.1016/j.ijthermalsci.2023.108333.
- [4] S. Ni, C. Pan, T. Hibiki, and J. Zhao, "Applications of nucleate boiling in renewable energy and thermal management and recent advances in modeling—a review," *Energy*, vol. 289, p. 129962, 2024. Doi: 10.1016/j.energy.2023.129962.

- [5] R. I. Elghanam, M. M. E. Fawal, R. A. Aziz, M. H. Skr, および A. H. Khalifa, 「実験的研究 界面活性剤を使用して沸騰熱伝達の増強を核形成する」、Ain Shams Engineering Journal, Vol. 2, 111-113, pp. 195–209, 2011. doi: 10.1016/j.asej.2011.09.001. G.
- [6] Liang and I. Mudawar, 「プール沸騰クリティカルヒートフラックス (CHF) - パート1: メカニズムのレビュー、モデル、および相関」、International Journal of Heat and Mass Transfer, Vol. 117, pp. 1352–1367, 2018. doi: 10.1016/j.jheatmasstransfer.2017.09.134. A.
- [7] Cabarcos, C. Paz, E. Suarez, および J. Vence, 「監視された学習アルゴリズムの適用 Nucleate Flow 沸騰の温度予測」、Applied Thermal Engineering, Vol. 240, p. 122155, 2024. doi: 10.1016/j.applthermaleng.2023.122155. D. H.
- [8] Kam, Y. H. Jeong, および H. C. No, 「CHF予測の熱伝達モデル開発開発 乾燥パッチの特性を考慮して」、International Journal of Heat and Mass Transfer, Vol. 148, p. 118812, 2020. doi: 10.1016/j.jheatmasstransfer.2019.118812. R.
- [9] Hernandez, C. P. Folsom, N. E. Woolstenhulme, C. B. Jensen, J. D. Bess, J. P. Gorton, および N. R. ブラウン, 「Pool 沸騰批判的熱流束 (CHF) と CHF 実験用のヒーターロッドのデザインのレビュー トリートで、」 核エネルギー, vol. 123, p. 103303, 2020. doi: 10.1016/j.pnucene.2020.103303.
- [10] A. K. Dixit, R. Kumar, and A. K. Das, “Investigation of film boiling at a liquid-liquid contact,” *International Journal of Heat and Mass Transfer*, vol. 196, p. 123234, 2022. Doi: 10.1016/j.jheatmasstransfer.2022.123234.
- [11] P. Goel, A. K. Nayak, P. P. Kulkarni, and J. B. Joshi, “Experimental study on bubble departure characteristics in subcooled nucleate pool boiling,” *International Journal of Multiphase Flow*, vol. 89, pp. 163–176, 2017. Doi: 10.1016/j.ijmultiphaseflow.2016.10.012.
- [12] L. Yuan, F. Hong, and P. Cheng, “Pool boiling enhancement through a guidance structure mounted above heating surface,” *International Journal of Heat and Mass Transfer*, vol. 139, pp. 751–763, 2019. Doi: 10.1016/j.jheatmasstransfer.2019.05.067.
- [13] V. I. Sharma, J. Buongiorno, T. J. McKrell, and L. W. Hu, “Experimental investigation of transient critical heat flux of water-based zinc-oxide nanofluids,” *International Journal of Heat and Mass Transfer*, vol. 61, pp. 425–431, 2013. Doi: 10.1016/j.jheatmasstransfer.2013.02.009.
- [14] K. Sinha, D. Ranjan, N. Kumar, M. Q. Raza, and R. Raj, “Simultaneous audio-visual-thermal characterization of transition boiling regime,” *Experimental Thermal and Fluid Science*, vol. 118, p. 110162, 2020. Doi: 10.1016/j.expthermflusci.2020.110162.
- [15] D. D. Hall and I. Mudawar, “Critical heat flux (CHF) for water flow in tubes—I. Compilation and assessment of world CHF data,” *International Journal of Heat and Mass Transfer*, vol. 43, no. 14, pp. 2573–2604, 2000. Doi: 10.1016/S0017-9310(99)00191-X.
- [16] A. Z. Mesquita and R. R. Rodrigues, “Detection of the Departure from Nucleate Boiling in Nuclear Fuel Rod Simulators,” *International Journal of Nuclear Energy*, vol. 2013, 2013.
- [17] A. B. Ponter and C. P. Haigh, “Sound emission and heat transfer in low pressure pool boiling,” *International Journal of Heat and Mass Transfer*, vol. 12, no. 4, pp. 413–428, 1969. Doi: 10.1016/0017-9310(69)90137-9.
- [18] K. Sinha, D. Ranjan, M. Q. Raza, N. Kumar, S. Kaner, A. Thakur, and R. Raj, “In-situ acoustic detection of critical heat flux for controlling thermal runaway in boiling systems,” *International Journal of Heat and Mass Transfer*, vol. 138, pp. 135–143, 2019. Doi: 10.1016/j.jheatmasstransfer.2019.04.029.
- [19] Y. Ueki and K. Ara, “Proof of concept of acoustic detection of boiling inception and state transition using deep neural network,” *International Communications in Heat and Mass Transfer*, vol. 129, p. 105675, 2021. Doi: 10.1016/j.icheatmasstransfer.2021.105675.
- [20] G. M. Hobold and A. K. da Silva, “Machine learning classification of boiling regimes with low speed, direct and indirect visualization,” *International Journal of Heat and Mass Transfer*, vol. 125, pp. 1296–1309, 2018. Doi: 10.1016/j.jheatmasstransfer.2018.04.156.
- [21] F. Al-Hindawi, T. Soori, H. Hu, M. M. R. Siddiquee, H. Yoon, T. Wu, and Y. Sun, “A framework for generalizing critical heat flux detection models using unsupervised image-to-image translation,” *Expert Systems with Applications*, vol. 227, p. 120265, 2023. Doi: 10.1016/j.eswa.2023.120265.
- [22] G. M. Hobold and A. K. da Silva, “Visualization-based nucleate boiling heat flux quantification using machine learning,” *International Journal of Heat and Mass Transfer*, vol. 134, pp. 511–520, 2019. Doi: 10.1016/j.jheatmasstransfer.2018.12.170.
- [23] R. Yamashita, M. Nishio, R. K. G. Do, and K. Togashi, “Convolutional neural networks: an 概要と放射線学におけるアプリケーション」、Insights to Imaging, Vol. 9, pp. 611–629, 2018. J.
- [24] Soibam, V. Scheiff, I. Aslanidou, K. Kyprianidis, および R. B. Fdhila, 「ディープラーニングの応用 サブクーリングされた沸騰におけるバブルダイナミクスのセグメンテーションのために」 Flow, vol. 169, p. 104589, 2023. doi: 10.1016/j.ijmultiphaseflow.2023.104589.

- [25] Y. Suh, R. Bostanabad, and Y. Won, "Deep learning predicts boiling heat transfer," *Sci Rep.* vol. 11, 2021. F. Nie, H. Wang, Q. Song, Y. Zhao, J. Shen, および M. Gong, 「二相流の画像識別 CNN アルゴリズムに基づくパターン」、International Journal of Multiphase Flow, Vol. 152, p. 104067, 2022. doi : 10.1016/j.ijmultiphaseflow.2022.104067.
- [26] M. M. Rashidi, M. A. Nazari, C. Harley, E. Momoniat, I. Mahariq, and N. Ali, "Applications of machine learning methods for boiling modeling and prediction: A comprehensive review," *Chemical Thermodynamics and Thermal Analysis*, vol. 8, p. 100081, 2022. Doi: 10.1016/j.ctta.2022.100081.
- [27] S. M. Rassoulinejad-Mousavi, F. Al-Hindawi, T. Soori, A. Rokoni, H. Yoon, H. Hu, T. Wu, and Y. Sun, "Deep learning strategies for critical heat flux detection in pool boiling," *Applied Thermal Engineering*, vol. 190, p. 116849, 2021. Doi: 10.1016/j.applthermaleng.2021.116849.
- [28] I. H. Sarker, "Machine Learning: Algorithms, Real-World Applications and Research Directions," *SN Computer Science*, vol. 2, 2021.
- [29] M. Conde-Fontenla, C. Paz, M. Concheiro, and G. Ribatski, "On the width and mean value of bubble size distributions under subcooled flow boiling," *Experimental Thermal and Fluid Science*, vol. 124, p. 110368, 2021. Doi: 10.1016/j.expthermflusci.2021.110368.
- [30] C. Paz, M. Conde, J. Porteiro, and M. Concheiro, "Effect of heating surface morphology on the size of bubbles during the subcooled flow boiling of water at low pressure," *International Journal of Heat and Mass Transfer*, vol. 89, pp. 770–782, 2015. Doi: 10.1016/j.ijheatmasstransfer.2015.06.003.
- [31] H. Jo, H. S. Ahn, S. Kang, and M. H. Kim, "A study of nucleate boiling heat transfer on hydrophilic, hydrophobic and heterogeneous wetting surfaces," *International Journal of Heat and Mass Transfer*, vol. 54, no. 25, pp. 5643–5652, 2011. Doi: 10.1016/j.ijheatmasstransfer.2011.06.001.
- [32] Y. Chen, R. Kong, and L. Kong, "Applications of artificial intelligence in astronomical big data," in *Big Data in Astronomy*, L. Kong, T. Huang, Y. Zhu, and S. Yu, Eds. Elsevier, 2020, pp. 347–375. Doi: 10.1016/B978-0-12-819084-5.00006-7.
- [33] M. Valizadeh and S. J. Wolff, "Convolutional Neural Network applications in additive manufacturing: A review," *Advances in Industrial and Manufacturing Engineering*, vol. 4, p. 100072, 2022. Doi: 10.1016/j.aime.2022.100072.
- [34] S. Indolia, A. K. Goswami, S. P. Mishra, and P. Asopa, "Conceptual Understanding of Convolutional Neural Network- A Deep Learning Approach," *Procedia Computer Science*, vol. 132, pp. 679–688, 2018. Doi: 10.1016/j.procs.2018.05.069.
- [35] D. Raval and J. N. Undavia, "A Comprehensive assessment of Convolutional Neural Networks for skin and oral cancer detection using medical images," *Healthcare Analytics*, vol. 3, p. 100199, 2023. Doi: 10.1016/j.health.2023.100199.
- [36] S. Kiranyaz, O. Avci, O. Abdeljaber, T. Ince, M. Gabbouj, and D. J. Inman, "1D convolutional neural networks and applications: A survey," *Mechanical Systems and Signal Processing*, vol. 151, p. 107398, 2021. Doi: 10.1016/j.ymssp.2020.107398.
- [37] S. Zahia, M. B. G. Zapiain, X. Sevillano, A. González, P. J. Kim, and A. Elmaghraby, "Pressure injury image analysis with machine learning techniques: A systematic review on previous and possible future methods," *Artificial Intelligence in Medicine*, vol. 102, p. 101742, 2020. Doi: 10.1016/j.artmed.2019.101742.
- [38] Y. Chandola, J. Virmani, H. S. Bhadauria, and P. Kumar, "End-to-end pre-trained CNN-based computer-aided classification system design for chest radiographs," in *Deep Learning for Chest Radiographs*, Y. Chandola, J. Virmani, H. S. Bhadauria, and P. Kumar, Eds. Academic Press, 2021, pp. 117–140. Doi: 10.1016/B978-0-323-90184-0.00011-4.
- [39] H. Ran, S. Wen, K. Shi, and T. Huang, "Stable and compact design of Memristive GoogLeNet Neural Network," *Neurocomputing*, vol. 441, pp. 52–63, 2021. Doi: 10.1016/j.neucom.2021.01.122.
- [40] E. Kim, G. S. Dahiya, S. Løset, and R. Skjetne, "Can a computer see what an ice expert sees? Multilabel ice objects classification with convolutional neural networks," *Results in Engineering*, vol. 4, p. 100036, 2019. Doi: 10.1016/j.rineng.2019.100036.
- [41] K. Liu, Z. Dai, R. Zhang, J. Zheng, J. Zhu, and X. Yang, "Prediction of the sulfate resistance for recycled aggregate concrete based on ensemble learning algorithms," *Construction and Building Materials*, vol. 317, p. 125917, 2022. Doi: 10.1016/j.conbuildmat.2021.125917.
- [42] B. Erkeyman, E. Erdem, T. Aydin, and Z. Mahmat, "New Artificial intelligence approaches for brand switching decisions," *Alexandria Engineering Journal*, vol. 63, pp. 625–643, 2023. Doi: 10.1016/j.aej.2022.11.043.
- [43] E. Okafor, M. Oyediji, and M. Alfarraj, "Deep reinforcement learning with light-weight vision model for sequential robotic object sorting," *Journal of King Saud University - Computer and Information Sciences*, vol. 36, no. 1, p. 101896, 2024. Doi: 10.1016/j.jksuci.2023.101896.

- [45] D. Sarwinda, R. H. Paradisa, A. Bustamam, and P. Anggia, "Deep Learning in Image Classification using Residual Network (ResNet) Variants for Detection of Colorectal Cancer," *Procedia Computer Science*, vol. 179, pp. 423–431, 2021. Doi: 10.1016/j.procs.2021.01.025.
- [46] M. A. Islam and G. Olm, "Deep learning techniques to detect rail indications from ultrasonic data for automated rail monitoring and maintenance," *Ultrasonics*, vol. 140, p. 107314, 2024. Doi: 10.1016/j.ultras.2024.107314.
- [47] H. Belyadi and A. Haghighat, "Supervised learning," in *Machine Learning Guide for Oil and Gas Using Python*, H. Belyadi and A. Haghighat, Eds. Gulf Professional Publishing, 2021, pp. 169–295. Doi: 10.1016/B978-0-12-821929-4.00004-4.
- [48] F. Guillon, N. Gierlinger, M.-F. Devaux, and A. Gorzsás, "In situ imaging of lignin and related compounds by Raman, Fourier-transform infrared (FTIR) and fluorescence microscopy," in *Lignin and Hydroxycinnamic Acids: Biosynthesis and the Buildup of the Cell Wall*, vol. 104, R. Sibout, Ed. Academic Press, 2022, pp. 215–270. Doi: 10.1016/bs.abr.2022.03.009.
- [49] J. Cai, "Applying support vector machine to predict the critical heat flux in concentric-tube open thermosiphon," *Annals of Nuclear Energy*, vol. 43, pp. 114–122, 2012. Doi: 10.1016/j.anucene.2011.12.029.
- [50] A. Urso, A. Fiannaca, M. L. Rosa, V. Ravì, and R. Rizzo, "Data Mining: Classification and Prediction," in *Encyclopedia of Bioinformatics and Computational Biology*, S. Ranganathan, M. Gribskov, K. Nakai, and C. Schönbach, Eds. Oxford: Academic Press, 2019, pp. 384–402. Doi: 10.1016/B978-0-12-809633-8.20461-5.